

## Teoria T02

Preencha o círculo dos itens verdadeiros e deixe em branco o dos falsos.

- ☐ Os dados para os quais  $y^{(i)}(w_0 + \mathbf{w}^T \mathbf{x}^{(i)})$  é exatamente igual a 0 (zero) são os vetores de suporte do modelo SVM.
- ☐  $w_0 + \mathbf{w}^T \mathbf{x}^{(i)} < -1$  if  $y^{(i)} = -1$  e  $w_0 + \mathbf{w}^T \mathbf{x}^{(i)} \geq 1$  if  $y^{(i)} = 1$  são restrições pertencentes ao problema de otimização do SVM em sua representação Dual.
- ☐ A grande vantagem da forma Dual no SVM é depender exclusivamente dos dados de entrada.
- ☐ O kernel RBF SVM permite criar combinações não lineares das características originais e, portanto, lidar com problemas não linearmente separáveis.
- ☐ O afrouxamento de margens no SVM linear é útil para lidar com ruídos nos dados de treinamento.
- ☐ Por falar em ruídos na base, valores grandes de k fazem modelos kNN mais suscetíveis aos mesmos.

Suponha que treinemos um SVM linear de margem rígida com  $n > 100$  exemplos em  $\mathbb{R}^2$ , gerando um hiperplano com exatos 2 vetores de suporte. Se adicionarmos mais um exemplo e retreinarmos o classificador, qual o número máximo possível de vetores de suporte para o novo hiperplano (assumindo que  $n+1$  exemplos são linearmente separáveis)?

- ☐ 2
- ☐ 3
- ☐ n
- ☐ n+1

Qual(is) do(s) seguinte(s) modelos podem conseguir erro zero de treinamento em qualquer base com dados linearmente separáveis? (Pinte todos que se aplicam)

- ☐ SVM de margem rígida
- ☐ kNN com  $k \gg 1$  (bem maior)
- ☐ Perceptron
- ☐ Adaline